

1. A visualização de dados é o primeiro passo porque ela revela padrões que nem sempre aparecem em tabelas. Um histograma pode mostrar assimetria, dispersão, multimodalidade e outliers. Uma matriz de dispersão pode revelar correlação entre variáveis, agrupamentos, relações não lineares e separação entre classes.
2. Uma distribuição uniforme tem frequências aproximadamente constantes em um intervalo. Uma distribuição normal concentra a maioria dos valores perto da média e diminui nas extremidades, formando o formato de sino. Um histograma é ideal para identificar essas formas porque mostra visualmente a frequência por faixa de valores.
3. Duas estratégias comuns para valores ausentes em uma coluna numérica são:
Remover as linhas com valores ausentes. Vantagem: simples e rápido. Desvantagem: pode reduzir muito o conjunto de dados e introduzir viés se os faltantes não forem aleatórios.
Preencher os valores ausentes com média ou mediana. Vantagem: preserva mais linhas. Desvantagem: pode distorcer a distribuição e reduzir a variabilidade real dos dados.
4. A função `try_or_none` tenta converter cada string em inteiro e retorna `None` quando não consegue.
5. O scaling é crucial em algoritmos baseados em distância porque variáveis em escalas maiores passam a dominar o cálculo. Em k-NN ou clustering, isso pode distorcer as vizinhanças e os grupos formados. Padronizar ou normalizar coloca as variáveis em uma escala comparável.
6. O `StandardScaler` transforma as variáveis para terem média zero e desvio padrão um, o que coloca altura e peso na mesma escala e evita que uma variável pese mais do que a outra.
7. A biblioteca `tqdm` mostra uma barra de progresso durante tarefas demoradas, ajudando a acompanhar o andamento da execução.
8. Quando você precisa do item e do índice, basta combinar `tqdm` com `enumerate`.
9. O argumento `leave=False` faz a barra de progresso sumir ao terminar o loop, o que deixa a saída mais limpa em loops aninhados.
10. Para integrar `tqdm` com `apply` no Pandas, use `tqdm.pandas()` e depois `progress_apply` para acompanhar o processamento linha por linha.