




Ciência de Dados

50 questões de revisão

Questão 1

Segundo Grus (2021), a Ciência de Dados combina estatística, computação e conhecimento de domínio. Qual das alternativas abaixo descreve corretamente a natureza interdisciplinar dessa área?

A

É uma subárea exclusiva da estatística clássica, sem relação com computação.

B

Combina estatística, computação e domínio de negócios para extrair insights de dados.

C

Equivale integralmente à Engenharia de Dados, focando em infraestrutura.

D

Restringe-se à criação de dashboards e relatórios descritivos.

E

É sinônimo de Business Intelligence, diferindo apenas nas ferramentas utilizadas.

Questão 2

Neto e Marques (2020) destacam que a Ciência de Dados fornece métodos para decisões baseadas em evidências. Qual dos três pilares fundamentais NÃO integra o núcleo da disciplina?

A

Estatística e Matemática

B

Ciência da Computação

C

Conhecimento de Domínio

D

Gestão de Recursos Humanos

E

Programação e Algoritmos

Questão 3

Janert (2011) afirma que a qualidade das conclusões depende da compreensão dos dados. Sobre dados estruturados e não estruturados, assinale a alternativa correta:

A

Dados estruturados incluem textos livres, imagens e vídeos.

B

Dados não estruturados representam cerca de 80% dos dados gerados no mundo.

C

Dados estruturados exigem técnicas especiais de processamento como NLP.

D

Dados não estruturados são sempre organizados em tabelas relacionais.

E

Não há distinção prática entre dados estruturados e não estruturados.

Questão 4

Faceli et al. (2011) classificam variáveis de acordo com sua natureza. Qual alternativa apresenta corretamente a classificação de "grau de escolaridade" (fundamental, médio, superior)?

A

Quantitativa contínua

B

Quantitativa discreta

C

Qualitativa nominal

D

Qualitativa ordinal

E

Binária booleana

Questão 5

Grolemund e Wickham (2016) popularizaram o pipeline de Ciência de Dados. Qual é a ordem correta das etapas desse framework iterativo?

A

Modelar → Importar →
Arrumar → Transformar →
Visualizar → Comunicar

B

Importar → Arrumar →
Transformar → Visualizar →
Modelar → Comunicar

C

Comunicar → Visualizar →
Modelar → Importar →
Arrumar → Transformar

D

Importar → Modelar →
Arrumar → Comunicar →
Visualizar → Transformar

E

Arrumar → Importar → Modelar → Transformar → Comunicar → Visualizar

Questão 6

Neto e Marques (2020) apresentam quatro tipos de analítica. Qual tipo responde à pergunta "Por que aconteceu?" e analisa causas-raiz em dados históricos?

A

Analítica Descritiva

B

Analítica Preditiva

C

Analítica Diagnóstica

D

Analítica Prescritiva

E

Analítica Exploratória

Questão 7

Comparando Ciência de Dados, Business Intelligence e Engenharia de Dados, qual alternativa descreve corretamente o foco principal da Engenharia de Dados?

A

Descobrir padrões e fazer previsões com modelos preditivos.

B

Reportar o que aconteceu por meio de dashboards e relatórios.

C

Construir e manter infraestrutura de dados como pipelines e data lakes.

D

Aplicar técnicas de machine learning supervisionado e não supervisionado.

E

Criar visualizações interativas com Power BI e Tableau.

Questão 8

John Tukey é considerado um dos pais da Ciência de Dados moderna. Qual foi sua principal contribuição para a área, segundo o material?

A

Criação do algoritmo MapReduce para processamento distribuído.

B

Defesa da Análise Exploratória de Dados (EDA) e publicação de *Exploratory Data Analysis* (1977).

C

Desenvolvimento da linguagem Python para análise estatística.

D

Criação do framework CRISP-DM para projetos de mineração de dados.

E

Publicação do paper seminal sobre redes neurais profundas.

Questão 9

Os "4 Vs" do Big Data descrevem as características dos grandes volumes de dados modernos. Qual alternativa apresenta corretamente todos os quatro Vs?

A

Volume, Velocidade,
Variedade e Veracidade

B

Volume, Valor, Visualização e
Velocidade

C

Variedade, Validação,
Veracidade e Virtualização

D

Velocidade, Virtualização,
Volume e Valor

E

Veracidade, Variedade, Validação e Visualização

Questão 10

Segundo o material, o mercado global de Ciência de Dados e Analytics cresceu de US\$ 35 bilhões em 2018 para quanto em 2024?

A

US\$ 100 bilhões

B

US\$ 150 bilhões

C

US\$ 180 bilhões

D

US\$ 210 bilhões

E

US\$ 250 bilhões

Questão 11

Faceli et al. (2011) definem aprendizado de máquina como a capacidade de um sistema melhorar seu desempenho a partir da experiência. Qual paradigma utiliza dados rotulados para treinar modelos?

A

Aprendizado por Reforço

B

Aprendizado Não
Supervisionado

C

Aprendizado Supervisionado

D

Aprendizado Semi-
supervisionado

E

Aprendizado Federado

Questão 12

O CRISP-DM é a metodologia mais utilizada em projetos de Ciência de Dados. Qual é a sequência correta de suas seis etapas?

A

Modelagem → Entendimento do Negócio → Preparação → Avaliação → Implantação → Dados

B

Entendimento do Negócio → Entendimento dos Dados → Preparação → Modelagem → Avaliação → Implantação

C

Preparação → Modelagem → Avaliação → Implantação → Negócio → Dados

D

Implantação → Avaliação → Modelagem → Preparação → Dados → Negócio

E

Entendimento dos Dados → Negócio → Modelagem → Preparação → Implantação → Avaliação

Questão 13

Janert (2011) observa que a maior parte do tempo de um cientista de dados é gasta em qual atividade?

A

Construção e otimização de modelos de deep learning.

B

Apresentação de resultados para stakeholders executivos.

C

Limpeza e preparação dos dados (45% do tempo).

D

Implantação de modelos em produção via APIs.

E

Coleta de requisitos junto às áreas de negócio.

Questão 14

Grus (2021) alerta que "com grande poder computacional vem grande responsabilidade". Qual caso real ilustra o viés algorítmico em sistemas de recrutamento?

A

Google descontinuou sistema de busca por penalizar resultados em português.

B

Amazon descontinuou sistema de triagem de currículos que penalizava candidatas mulheres.

C

Microsoft removeu chatbot por gerar respostas ofensivas sobre política.

D

Facebook suspendeu algoritmo de recomendação por viés etário.

E

Netflix descontinuou sistema de recomendação por discriminar gêneros cinematográficos.

Questão 15

A LGPD (Lei nº 13.709/2018) estabelece regras para tratamento de dados pessoais no Brasil. Qual princípio determina que apenas os dados estritamente necessários devem ser coletados?

A

Transparência

B

Responsabilidade

C

Equidade

D

Minimização

E

Portabilidade

Questão 16

Pesquisas citadas no material indicam que 87% dos americanos podem ser reidentificados pela combinação de três atributos. Quais são eles?

A

Nome, e-mail e número de telefone

B

CEP, data de nascimento e gênero

C

CPF, endereço e profissão

D

IP, localização e histórico de navegação

E

Renda, estado civil e escolaridade

Questão 17

Em Python, qual das alternativas abaixo representa corretamente uma atribuição múltipla de variáveis em uma única linha?

A

```
x = 1; y = 2; z = 3
```

B

```
x, y, z = 1, 2, 3
```

C

```
x = y = z = (1, 2, 3)
```

D

```
int x = 1, y = 2, z = 3
```

E

```
x := 1, y := 2, z := 3
```

Questão 18

Sobre os operadores lógicos em Python, qual alternativa descreve corretamente o comportamento de `X and Y`?

A

Se X é verdadeiro, retorna X;
caso contrário, retorna Y.

B

Se X é falso, retorna X; caso
contrário, retorna Y.

C

Sempre retorna True ou False,
nunca os valores originais.

D

Retorna True apenas se
ambos forem inteiros
positivos.

E

Equivale ao operador `|` em Python.

Questão 19

Considere o código: `for x in range(-1, 6, 2): print(x)`. Qual será a saída correta?

A

-1, 0, 1, 2, 3, 4, 5

B

-1, 1, 3, 5

C

0, 2, 4, 6

D

-1, 2, 5

E

1, 3, 5

Questão 20

Sobre list comprehension em Python, qual das alternativas gera corretamente uma lista com os quadrados dos números ímpares de 1 a 10?

A

```
[x**2 for x in range(1,11) if  
x%2==0]
```

B

```
[x**2 for x in range(1,11) if  
x%2!=0]
```

C

```
[x*2 for x in range(1,11) if  
x%2==1]
```

D

```
[x**2 for x in range(0,10) if  
x%2!=0]
```

E

```
[x for x**2 in range(1,11) if x%2!=0]
```

Questão 21

Qual é a principal diferença entre listas e tuplas em Python, segundo o material?

A

Listas permitem duplicatas;
tuplas não permitem
elementos repetidos.

B

Tuplas são mutáveis e mais
lentas; listas são imutáveis e
mais rápidas.

C

Listas são mutáveis; tuplas
são imutáveis e mais rápidas
para dados fixos.

D

Tuplas suportam indexação;
listas não suportam acesso
por índice.

E

Listas são criadas com `()`; tuplas são criadas com `[]`.

Questão 22

Sobre dicionários em Python, qual método retorna todos os pares chave-valor como uma sequência de tuplas?

A

`.keys()`

B

`.values()`

C

`.items()`

D

`.pairs()`

E

`.tuples()`

Questão 23

Sobre conjuntos (sets) em Python, qual operação retorna apenas os elementos presentes em ambos os conjuntos a e b?

A

$a \mid b$

B

$a - b$

C

$a \& b$

D

$a \wedge b$

E

$a + b$

Questão 24

O `Counter` do módulo `collections` é utilizado para contar elementos de iteráveis. Dado `Counter("banana")`, qual será o resultado?

A

```
Counter({'b': 1, 'a': 1, 'n': 1})
```

B

```
Counter({'a': 3, 'n': 2, 'b': 1})
```

C

```
Counter({'b': 3, 'a': 2, 'n': 1})
```

D

```
Counter({'n': 3, 'a': 2, 'b': 1})
```

E

```
Counter({'banana': 1})
```

Questão 25

Sobre funções com `*args` e `**kwargs` em Python, qual alternativa está correta?

A

`*args` agrupa argumentos nomeados em um dicionário;
`**kwargs` agrupa posicionais em uma tupla.

B

`*args` agrupa argumentos posicionais em uma tupla;
`**kwargs` agrupa nomeados em um dicionário.

C

Ambos agrupam argumentos em listas Python.

D

`*args` é obrigatório em toda função Python.

E

`**kwargs` só pode ser usado com funções lambda.

Questão 26

Qual é a saída do código abaixo?

```
dobro = lambda x: x * 2  
nums = [1,2,3,4,5,6]  
pares = list(filter(lambda x: x%2==0, nums))  
print(pares)
```

A

[1, 3, 5]

B

[2, 4, 6, 8, 10, 12]

C

[2, 4, 6]

D

[1, 2, 3, 4, 5, 6]

E

[0, 2, 4, 6]

Questão 27

Sobre herança em Python, qual função é usada dentro de uma subclasse para chamar o construtor da classe pai?

A

`parent.__init__()`

B

`base().__init__()`

C

`super().__init__()`

D

`self.parent()`

E

`inherit().__init__()`

Questão 28

No encapsulamento em Python, como se declara um atributo privado em uma classe, de forma que ele não seja acessível diretamente fora dela?

A

Usando o prefixo `private_` antes do nome.

B

Usando o prefixo `__` (dois underscores) antes do nome.

C

Declarando o atributo fora do método `__init__`.

D

Usando a palavra-chave `private` antes do atributo.

E

Usando o prefixo `#` antes do nome do atributo.

Questão 29

Qual das formas de importação abaixo é considerada **não recomendada** em projetos profissionais por gerar ambiguidade e potenciais conflitos de nomes?

A

```
import math
```

B

```
from math import sqrt
```

C

```
import numpy as np
```

D

```
from math import *
```

E

```
from datetime import date
```

Questão 30

A função `zip()` em Python combina iteráveis elemento a elemento. O que acontece quando os iteráveis têm tamanhos diferentes?

A

Gera um erro `ValueError` indicando tamanhos incompatíveis.

B

Preenche os elementos faltantes com `None` automaticamente.

C

Para quando o iterável mais curto se esgota.

D

Repete os elementos do iterável mais curto até igualar o maior.

E

Retorna apenas os elementos do iterável mais longo.

Questão 31

NumPy é descrito como a biblioteca fundamental para computação científica em Python. Qual é a principal vantagem da vetorização em NumPy em relação a loops Python explícitos?

A

Permite usar sintaxe mais próxima da linguagem C diretamente no Python.

B

Delega operações ao núcleo C otimizado, resultando em código mais rápido e limpo.

C

Elimina a necessidade de importar o módulo NumPy em cada arquivo.

D

Garante que os arrays sejam sempre imutáveis, como tuplas.

E

Converte automaticamente listas Python em dicionários otimizados.

Questão 32

Qual propriedade de um array NumPy retorna o número total de elementos (produto de todas as dimensões)?

A

`.shape`

B

`.ndim`

C

`.dtype`

D

`.size`

E

`.len`

Questão 33

Dado `arr = np.array([[1,2,3,4],[5,6,7,8],[9,10,11,12]])`, qual é o resultado de `arr[:, 1:3]`?

A

`[[1,2],[5,6],[9,10]]`

B

`[[2,3],[6,7],[10,11]]`

C

`[[3,4],[7,8],[11,12]]`

D

`[[1,2,3],[5,6,7],[9,10,11]]`

E

`[[2,3,4],[6,7,8],[10,11,12]]`

Questão 34

Qual função NumPy cria uma sequência de 5 valores igualmente espaçados entre 0 e 1, incluindo os extremos?

A

```
np.arange(0, 1, 5)
```

B

```
np.range(0, 1, 5)
```

C

```
np.linspace(0, 1, 5)
```

D

```
np.space(0, 1, 5)
```

E

```
np.sequence(0, 1, 5)
```


Questão 35

Dado `arr = np.array([1,3,7,2,9,4,6,8,5])`, qual é o resultado de `arr[arr > 5]`?

A

`[1, 3, 2, 4, 5]`

B

`[7, 9, 6, 8]`

C

`[6, 7, 8, 9]`

D

`[True, False, True, False, True,
False, True, True, False]`

E

`[5, 6, 7, 8, 9]`

Questão 36

Qual é a diferença entre `np.dot(A, B)` e `A * B` para arrays 2D em NumPy?

A

Não há diferença; ambos realizam o produto matricial clássico.

B

`np.dot(A, B)` realiza o produto matricial; `A * B` realiza multiplicação elemento a elemento.

C

`A * B` realiza o produto matricial; `np.dot(A, B)` realiza multiplicação elemento a elemento.

D

Ambos realizam multiplicação elemento a elemento (Hadamard).

E

`np.dot(A, B)` só funciona com arrays 1D; `A * B` funciona com qualquer dimensão.

Questão 37

Para calcular a mediana de um array NumPy `arr`, qual é a forma correta?

A

```
arr.median()
```

B

```
arr.med()
```

C

```
np.median(arr)
```

D

```
np.mean(arr)
```

E

```
arr.percentile(50)
```

Questão 38

Dado `arr = np.array([[1,2],[3,4]])`, qual é o resultado de `arr.sum(axis=0)`?

A

`[3, 7]`

B

`[4, 6]`

C

`[10]`

D

`[[1,2],[3,4]]`

E

`[1, 2, 3, 4]`

Questão 39

Qual método NumPy muda a forma de um array sem alterar seus dados, e como usar -1 como argumento?

A

`.flatten(-1)` — inverte a ordem dos elementos.

B

`.reshape(-1)` — converte o array para 1D, calculando automaticamente o tamanho.

C

`.T(-1)` — transpõe e reduz a dimensão.

D

`.resize(-1)` — remove todos os elementos negativos.

E

`.ravel(-1)` — cria uma cópia invertida do array.

Questão 40

Para garantir reprodutibilidade em experimentos com números aleatórios no NumPy, qual função deve ser utilizada antes de gerar os dados?

A

```
np.random.reset()
```

B

```
np.random.fix(42)
```

C

```
np.random.seed(42)
```

D

```
np.set_seed(42)
```

E

```
np.random.lock(42)
```

Questão 41

Qual das alternativas abaixo cria corretamente uma matriz identidade 4x4 com NumPy?

A

```
np.zeros((4,4))
```

B

```
np.ones((4,4))
```

C

```
np.identity((4,4))
```

D

```
np.eye(4)
```

E

```
np.diag(4)
```

Questão 42

Dado `a = np.array([1,2,2,3,4,4,4,5])`, qual função NumPy retorna os valores únicos do array?

A

`np.distinct(a)`

B

`np.unique(a)`

C

`np.deduplicate(a)`

D

`a.unique()`

E

`set(a)`

Questão 43

O Pandas é descrito como a biblioteca mais poderosa do ecossistema Python para Ciência de Dados. Qual é a estrutura de dados central do Pandas para dados tabulares (linhas e colunas)?

A

ndarray

B

Series

C

DataFrame

D

Matrix

E

Table

Questões 44 a 47

1

Questão 44

Qual biblioteca Python é fundamental para machine learning, contendo algoritmos como regressão, classificação e clustering?

A) TensorFlow B) Matplotlib C) scikit-learn D) Seaborn E) SciPy

2

Questão 45

No ecossistema Python para Ciência de Dados, qual pacote do *tidyverse* equivalente em R é utilizado para manipulação e limpeza de dados tabulares?

A) caret B) ggplot2 C) Shiny D) dplyr/tidyr E) RStudio

3

Questão 46

Qual técnica de privacidade adiciona ruído controlado aos dados para proteger registros individuais, preservando propriedades estatísticas agregadas?

A) K-anonimidade B) Pseudonimização C) Privacidade diferencial D) Dados sintéticos E) Criptografia simétrica

4

Questão 47

Qual paradigma de Machine Learning utiliza um agente que aprende por tentativa e erro, recebendo recompensas por ações corretas?

A) Supervisionado B) Não Supervisionado C) Semi-supervisionado D) Por Reforço E) Federado

Questões 48 a 50

Questão 48

Segundo o material, qual algoritmo de Machine Learning é indicado para segmentar clientes em grupos homogêneos com base em comportamento de compra?

- A)** Regressão Linear **B)** Árvore de Decisão
C) K-Means **D)** Redes Neurais **E)** SVM

Questão 49

A ANPD fiscaliza o cumprimento da LGPD no Brasil. Qual é o valor máximo de multa previsto para empresas infratoras?

- A)** 1% do faturamento **B)** 2% do faturamento
C) 5% do faturamento **D)** R\$ 50 milhões fixos
E) 10% do lucro líquido

Questão 50

Qual das alternativas abaixo empilha verticalmente dois arrays 1D `[1,2,3]` e `[4,5,6]` para formar um array 2D em NumPy?

- A)** `np.hstack([a,b])` **B)** `np.concatenate([a,b])`
C) `np.vstack([a,b])`
D) `np.append(a,b)` **E)** `np.stack(a,b)`

Questão 51

Qual biblioteca Python é comumente usada para conectar-se a um banco de dados MySQL e executar consultas?

A

sqlite3

B

psycopg2

C

pymysql

D

mongoengine

E

redis-py

Questão 52

Qual biblioteca Python é mais comumente usada para interagir com um banco de dados MySQL de forma programática?

A

psycopg2

B

sqlite3

C

mysql.connector

D

pymongo

E

redis-py

Questão 53

Qual é o propósito principal da biblioteca SQLAlchemy em projetos de Ciência de Dados com Python e MySQL?

A

Facilitar a criação de interfaces gráficas para bancos de dados.

B

Converter arquivos CSV diretamente em tabelas MySQL sem codificação adicional.

C

Atuar como um Mapeador Objeto-Relacional (ORM), permitindo interagir com o banco de dados usando objetos Python.

D

Monitorar o desempenho do servidor MySQL em tempo real.

E

Realizar apenas operações de backup e restauração de dados MySQL.

Questão 54

Qual biblioteca Python é utilizada para interagir com o Firebase (ex: Cloud Firestore, Realtime Database) em projetos de Ciência de Dados?

A

firebase-database

B

pyrebase

C

firestore-python

D

firebase-admin

E

google-cloud-storage

Questão 55

Ao usar a biblioteca `mysql.connector` em Python para inserir dados de um Pandas DataFrame em uma tabela MySQL, qual das abordagens abaixo é a mais eficiente para inserir múltiplas linhas de uma vez?

A

Loop através do DataFrame e executar uma declaração `INSERT` para cada linha.

B

Usar `executemany()` com uma declaração `INSERT INTO ... VALUES (%s, %s, ...)` e uma lista de tuplas de dados.

C

Converter o DataFrame para um único string SQL gigante e executá-lo.

D

Utilizar o método `cursor.insert_many(df)`.

E

Exportar o DataFrame para um arquivo CSV e depois usar o comando `LOAD DATA INFILE` diretamente no MySQL.